Großputz im CMS!

Semantische Ähnlichkeitsanalyse für XML-Module

Jan Oevermann (ICMS)
Timo Fleschutz-Balarezo (SIEMENS)



Content Management bei Siemens Gas Turbines Berlin

- Dokumentation
 - Produkthandbuch und interne Vertriebsinformationen für Gasturbinen für Großkraftwerke (13 Mitarbeiter)
 - Aktuell 5 Produktfamilien in verschiedenen Versionen und kundenspezifischen Anpassungen
 - Über 300.000 Textbausteine in mehreren Sprachen







Content Management bei Siemens Gas Turbines Berlin

-System

- 2015 Umstieg von Word-basiertem
 System auf XML-basiertes CMS
 TechPub Studio
- Maschinelle Migration der Word-Dokumente in PI-Mod XML-Module

```
<descriptive nodeid="PI-70006536">
  <heading>Fuel Gas Requirements</heading>
  <descriptive body>
    <paragraph>This Section defines [...]
      <row>
        <entry>
          <paragraph>Permissible range</paragraph>
        </entry>
        <entry>
           <paragraph>
             <inlinedata>
               <si-value>
                 <number>5</number>
                 <unit>°C</unit>
               </si-value>
             </inlinedata>to
             <inlinedata>
               <si-value>
                 <number>120</number>
                 <unit>°C</unit>
               </si-value>
             </inlinedata>
           </paragraph>
```

Auslöser und Folgen von Duplikaten

- Dokumentbasierte Migration
- Multiautorenumgebung
 - Nicht-Finden von existierenden Modulen
- UnkontrollierteWiederverwendung
 - Copy & Paste

- Negative Auswirkungen auf Information Retrieval
 - Hoher Recall, niedrige
 Precision
- -Höhere Übersetzungskosten
- Höhere Time-to-Market,
 durch doppelte Erfassung



Ähnlichkeit

This device is designed to work with a voltage of 220 V only

The only voltage this device is designed for is 220 V

Ähnlichkeit - Diffing

1 This device is designed to work with a voltage of 220 V only

This only voltage this device is designed for to is work with a voltage of 220 V only.

2 The only voltage this device is designed for is 220 V

This The only voltage this device works is with designed a for voltage is of 220 V only.

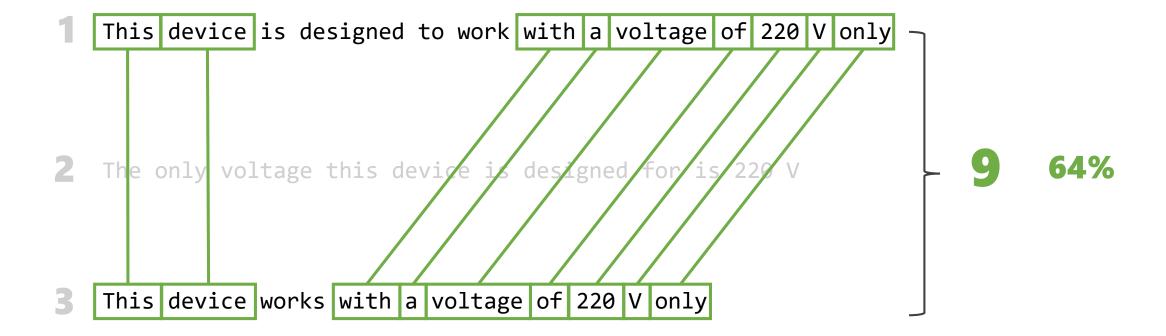


Ähnlichkeit

This device is designed to work with a voltage of 220 V only

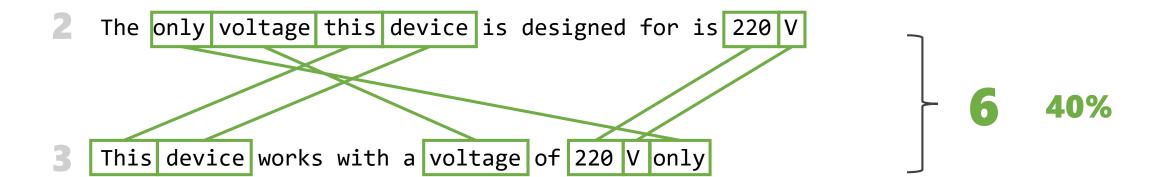
The only voltage this device is designed for is 220 V

Ähnlichkeit - Einfach

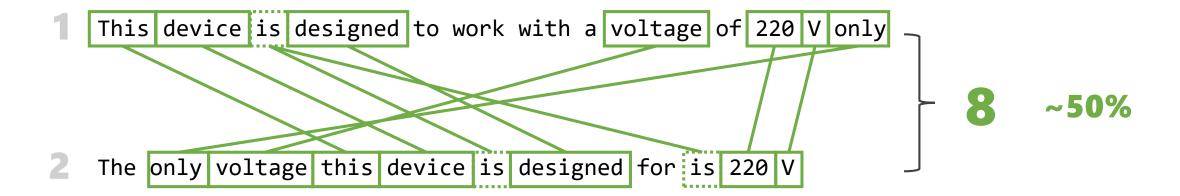


Ähnlichkeit - Einfach

1 This device is designed to work with a voltage of 220 V only



Ähnlichkeit - Einfach



Ähnlichkeit - Kosinus

This device is designed to work with a voltage of 220 V only

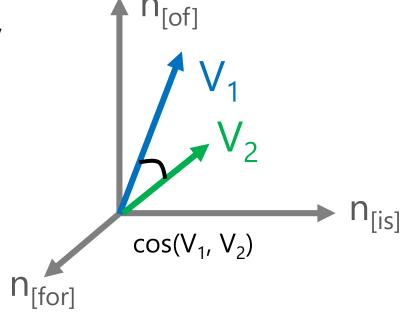
The only voltage this device is designed for is 220 V



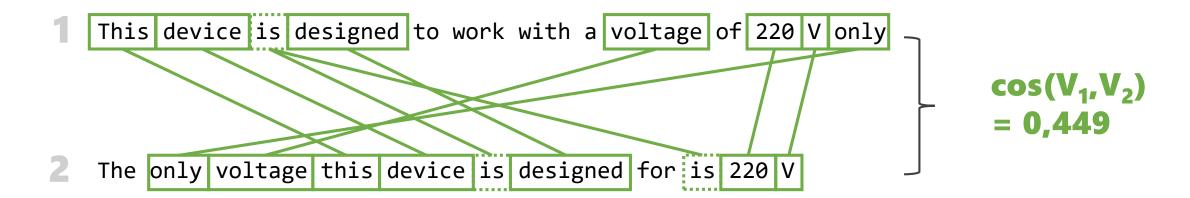
Ähnlichkeit - Kosinus

This device is designed to work with a voltage of 220 V only

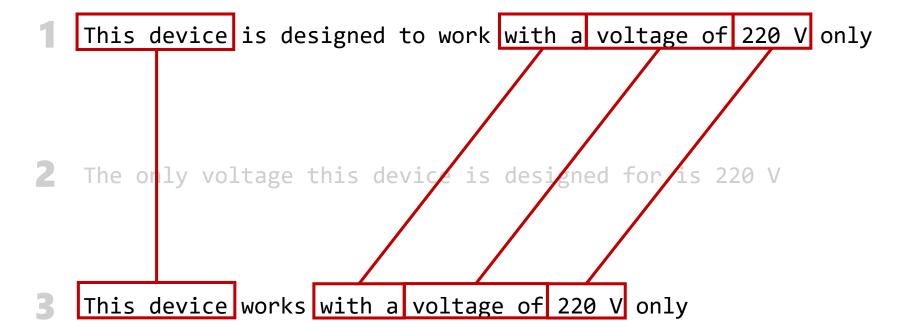
2 The only voltage this device is designed for is 220 V



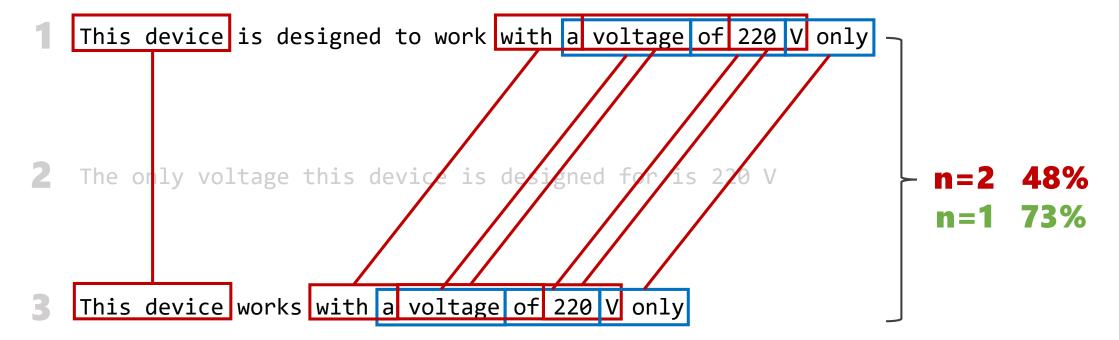
Ähnlichkeit - Kosinus



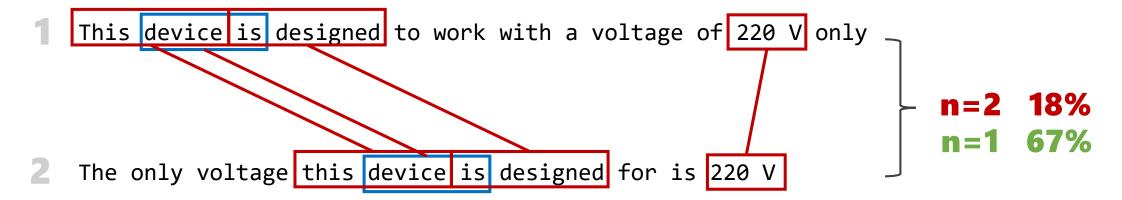
Ähnlichkeit - Wortgruppen



Ähnlichkeit - Wortgruppen



Ähnlichkeit - Wortgruppen



Semantische Ähnlichkeit

This device is designed to work with a voltage of 220 V only

The only voltage this device is designed for is 220 V

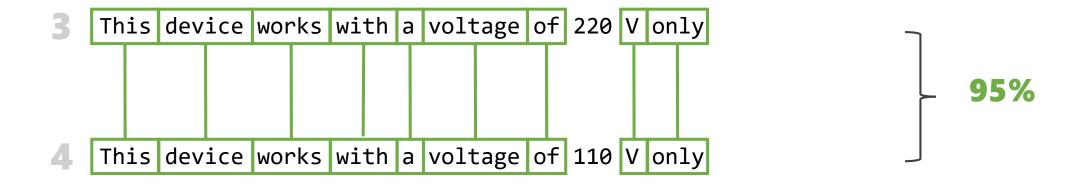
This device works with a voltage of 220 V only



Semantische Ähnlichkeit

1 This device is designed to work with a voltage of 220 V only

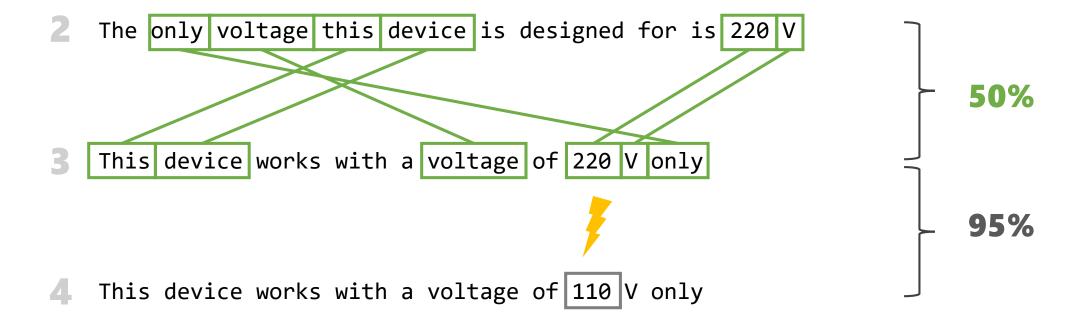
2 The only voltage this device is designed for is 220 V





Semantische Ähnlichkeit

1 This device is designed to work with a voltage of 220 V only

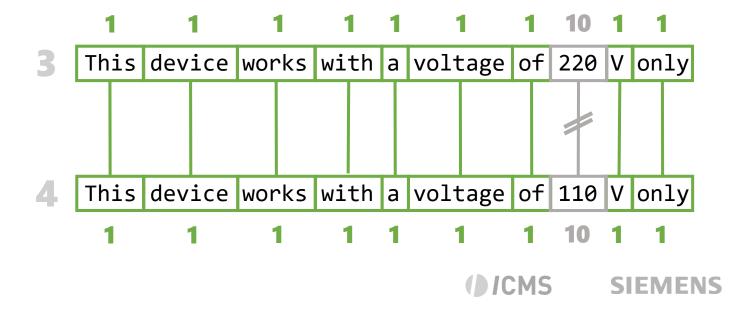




Semantische Gewichtung

1 This device is designed to work with a voltage of 220 V only

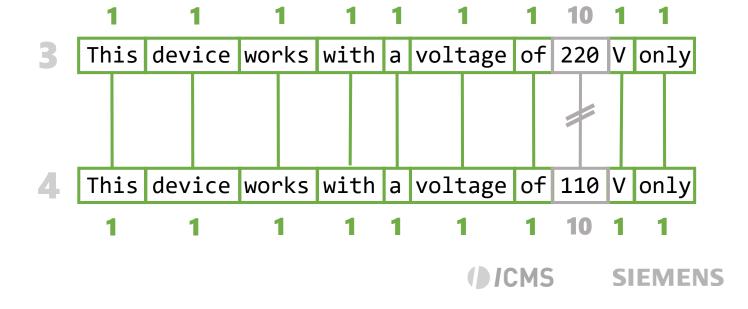
2 The only voltage this device is designed for is 220 V

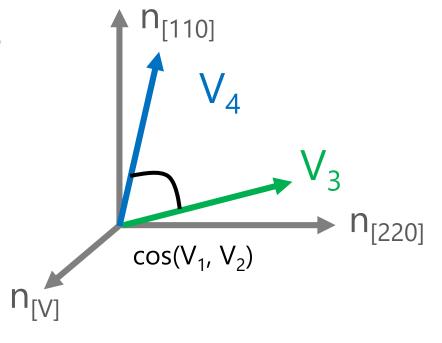


Semantische Gewichtung

1 This device is designed to work with a voltage of 220 V only

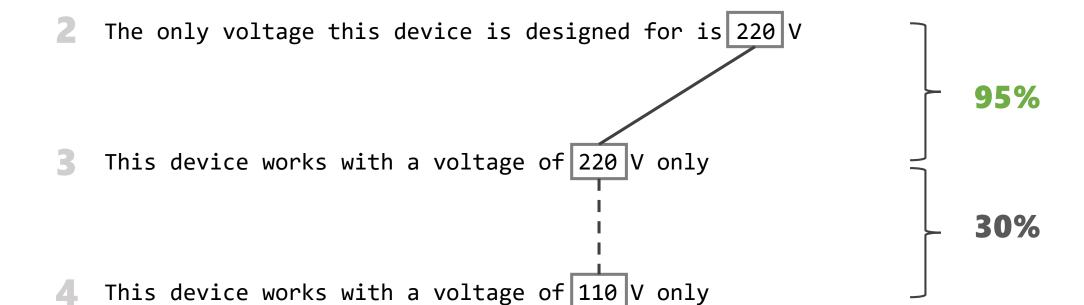
2 The only voltage this device is designed for is 220 V





Semantische Gewichtung

1 This device is designed to work with a voltage of 220 V only





Semantisches Informationsmodell

Semantisches Informationsmodell

Projektanforderungen & Lösungsansätze

Sehr große Anzahl an zu vergleichenden Bausteinen

Verwendung eines Algorithmus mit hoher Berechnungseffizienz

Einfache Kennzahl für die Vergleichbarkeit von Bausteinen Zuverlässigkeit gegenüber semantisch gleichen Unterschieden

Erkennung von gewollten Varianten

Gewichtung von semantisch wichtigen Bestandteilen

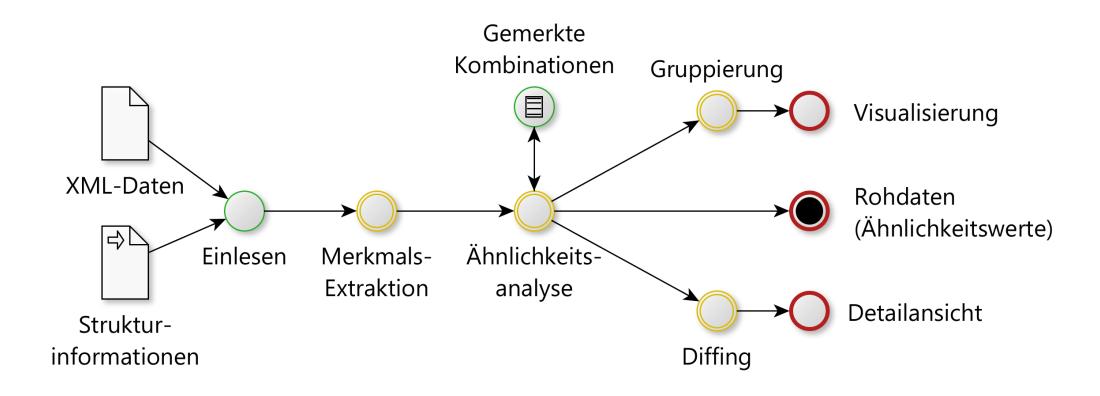
Qualitätssicherung

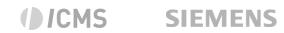
Benutzeroberfläche zur manuellen Überprüfung



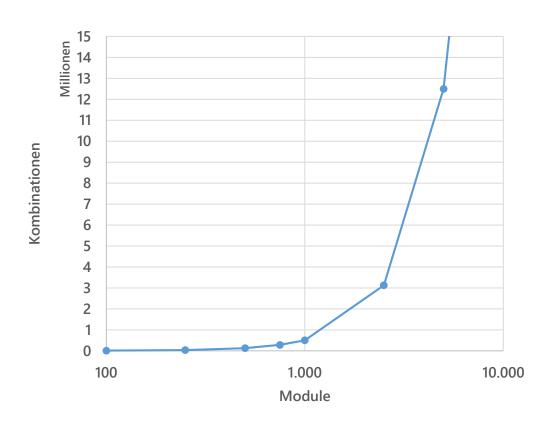


Architektur



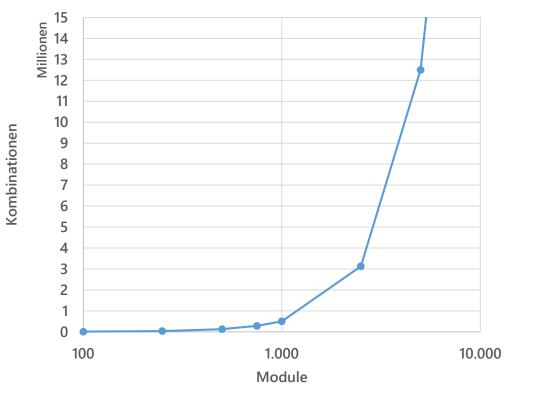


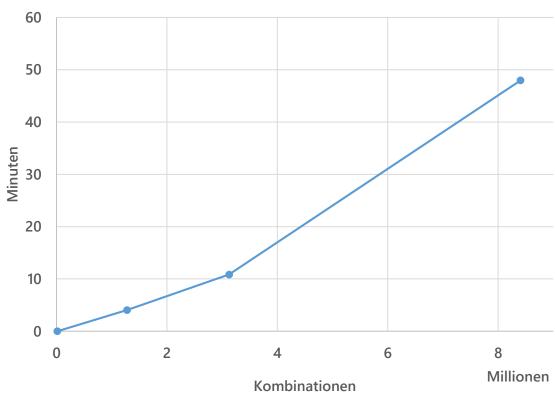
Skalierung



$$|C| = \frac{n*(n-1)}{2}$$

Skalierung





Technologie & Forschung

- Implementiert in JavaScript
- Berechnungen im Browser (lokal)
- Möglichkeiten für Speichern / Export
- Prototyp verfügbar: http://semsim.fastclass.de
- Paper:

OEVERMANN J. / LÜTH C. (2018): Semantically Weighted Similarity Analysis for XML-based Content Components. Proceedings of the 18th ACM Symposium on Document Engineering. DocEng 2018, Halifax, Canada.



Live Demo

fast**class**



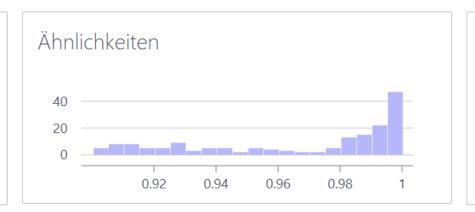
SIEMENS Demo 1

Duplikate

Ähnlichkeitsbeziehungen

173

bei 13695 Kombinationen



Ergebnisse sichern 🔻

Neue Analyse

Zeit

Benötigte Zeit

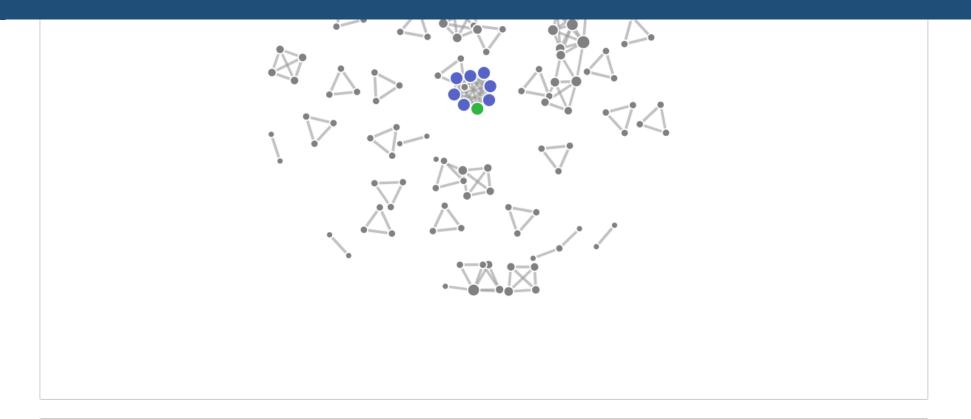
0.61s

für 166 analysierte Objekte

Objektähnlichkeiten

Cluster von ähnlichen oder duplikaten Objekten.





Detailansicht Änhlichkeitswerte

Tabellarische Übersicht der Ähnlichkeiten

PI-70116789 ×

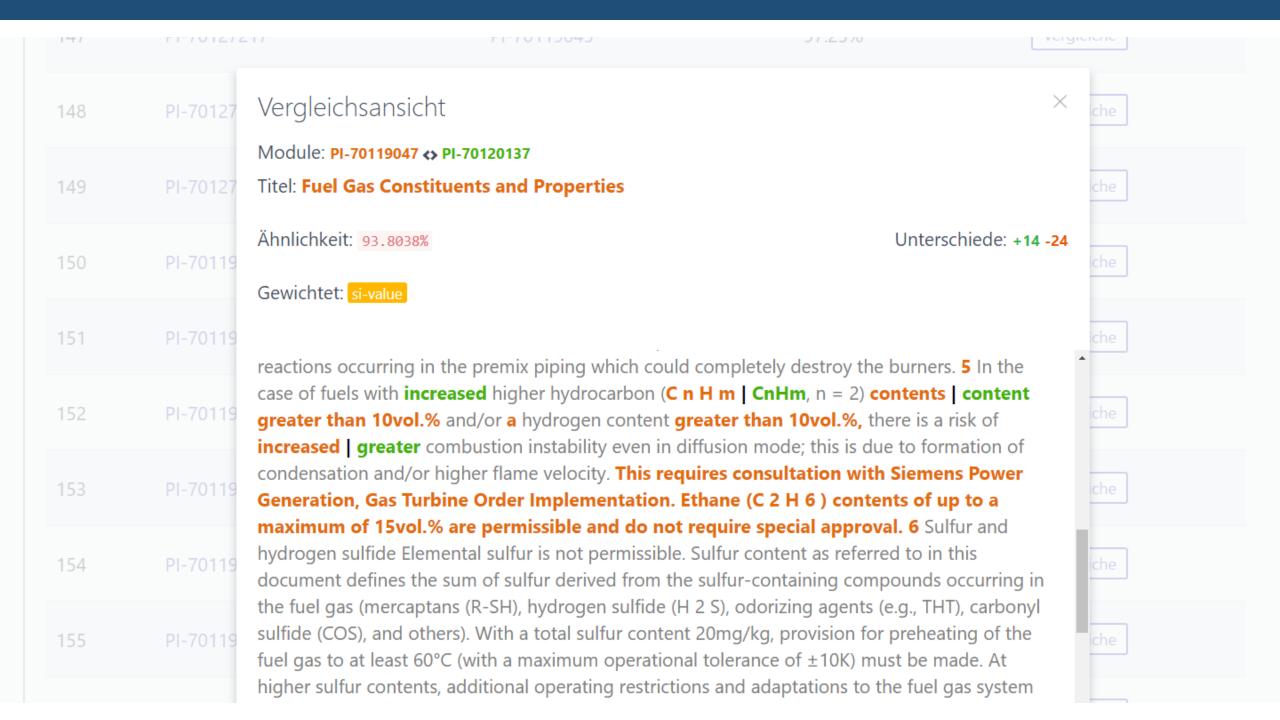
#	Modul-ID	Modul-ID	Ähnlichkeit	Aktion
59	PI-70006797	PI-70116789	98.61%	Vergleiche
105	PI-70163367	PI-70116789	98.88%	Vergleiche
138	PI-70148781	PI-70116789	99.13%	Vergleiche

Detailansicht Änhlichkeitswerte

Tabellarische Übersicht der Ähnlichkeiten

PI-70116789 ×

#	Modul-ID	Modul-ID	Ähnlichkeit	Aktion
59	PI-70006797	PI-70116789	98.61%	Vergleiche
105	PI-70163367	PI-70116789	98.88%	Vergleiche
138	PI-70148781	PI-70116789	99.13%	Vergleiche
142	PI-70127224	PI-70116789	100%	Vergleiche
151	PI-70119052	PI-70116789	91.8%	Vergleiche
161	PI-70119042	PI-70116789	99.02%	Vergleiche
169	PI-70116789	PI-70120142	99.02%	Vergleiche



Anpassungen im Projektverlauf

- -Filter zum Import von XML-Daten
- -Integration eines Textvergleichs zur schnellen Überprüfung
- -Dynamische Filterung und Markierung der gewählten Bausteine
- -Vorschau der Überschrift in der Übersichtstabelle
- -Selektive Zusammenstellung der Quelltexte für den Vergleich auf Basis der inhaltlichen Struktur



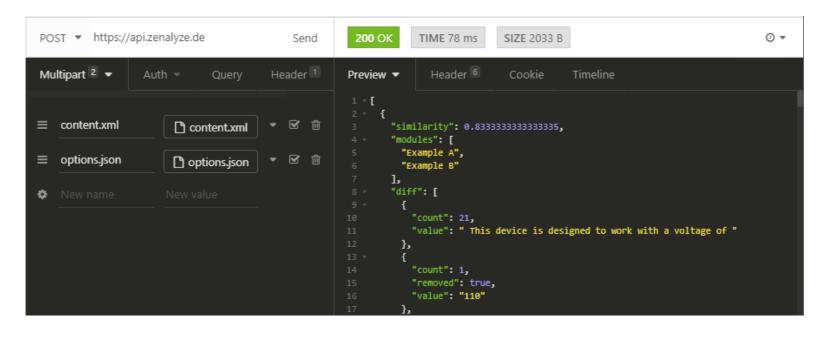
Ausblick

- -Optimierungspotenziale
 - Erweiterung zum Abgleich neuer Texte mit bestehenden Bausteinen
 - Integration von Metadaten / Klassifizierungen zur Unterstützung der Entscheidungsfindung
- -Anwendungsszenarien
 - Überarbeitung von bestehender Dokumentation zur Reduzierung der Textbausteine
 - Versionsvergleich von Dokumentationen
 - Prognose Übersetzungskosten



Ausblick

- -Weiterentwicklung
 - Alternative Dateiformate (iiRDS, DITA, etc.)
 - Direkte Systemintegration
 - API als Webservice



Vielen Dank für Ihre Aufmerksamkeit



Jan Oevermann jan.oevermann@icms.de



Dr. Timo Fleschutz-Balarezo timo.fleschutz@siemens.com

Besuchen Sie uns an Stand G07 in Halle C2



SIEMENS

Ingenuity for life





Ihre Meinung ist uns wichtig! Sagen Sie uns bitte, wie Ihnen der Vortrag gefallen hat. Wir freuen uns auf Ihr Feedback per Smartphone oder Tablet unter:

http://in11.honestly.de

oder scannen Sie den QR-Code.



Das Bewertungstool steht Ihnen auch noch nach der Tagung zur Verfügung!